

观心 v2 演进路线：复核与决策版

2026-09-07 · 面向产品与技术负责人 · 当前代码基线 6178918

核心结论

建议最终建设一个企业 AI 任务工作台：用户提交目标与授权资料，系统持续完成研究、分析和受控行动，交付可修订、可核查的文件与业务结果。平台负责身份、任务状态、权限、预算、审批和产物；执行器负责在这些约束内选择工具并推进任务。

保留观心现有 FastAPI、LangGraph、AI SDK、知识库和写工作流。Deep Agents SDK 是优先实验的复杂任务执行器；Claude Code 提供任务闭环与交互参照；DeepSeek Harness 提供能力模块和事件架构参照。当前证据支持渐进接入，尚不足以决定整体替换核心。

三组参考的适用位置

对象	本轮核实	对观心的建议
Claude Code	官方描述收集上下文、行动、验证的循环；支持多种界面。第三方中文入口的“无 GUI”不能作为现行官方规格	借鉴持续验证、中途纠正、上下文管理。需编码专长时另评估 Agent SDK
Deep Agents	dcode 是终端产品；SDK 是可嵌入的 harness。v0.7 的规划仍为可选，默认工具与文件权限需显式收口	独立环境试验，先限于研究与报告；保留平台鉴权和前端协议
DeepSeek Harness	Cordis 插件化架构；安全说明仍标实验预览且未做安全审计	先借鉴能力接口、执行策略与事实事件；运行时接入采用隔离适配器

来源：[Anthropic：运行机制](#)、[用户给定第三方入口](#)、[LangChain：Code](#)、[SDK 概览](#)、[DeepSeek：架构](#)、[安全说明](#)。
以上本轮于 2026-09-07 读取；页面发布日期未核实。

相比 9 月 4 日版的新增发现

本地 6178918 提交加入上一版报告和附件界面调整；相对 a59fd0c，backend 没有提交差异，当前工作树干净。后端仍处于 v0.2.0-demo 基线，不能将提交报告视为路线已实施。

Deep Agents main 的版本字段仍为 0.7.13，但 core 最低依赖本轮显示为 1.6.2，上一轮为 1.6.1。PyPI 可见发布记录仍为 0.7.13。main 和已发布 wheel 的内容不能据版本号视为相同；实验必须记录发布包哈希、实际解析依赖与对应源码。[官方 main 依赖](#)、[PyPI](#)

技术路线：先把一个任务做完整

目标架构与归属

用户入口 → 观心任务控制层 → 可替换执行器 → 受控工具与工作区。任务控制层保存 owner、goal、budget、status、产物与审核结果。执行器可先用现有研究逻辑；未来经适配接入 Deep Agents。业务写操作继续由现有 workflow 执行，恢复前重新校验权限。

不要让新执行器同时拥有另一套认证、审批和用户可见任务状态。LangGraph checkpoint 保存执行位置；TaskRun 保存业务状态；Artifact 保存结果及版本；关键运行事件用于重连与追溯。先新增最小关联字段和适配接口，不要求第一版把全部历史表迁成事件溯源系统。

第一条黄金路径

“读取授权资料和公开来源 → 研究指定问题 → 生成带证据的报告 → 用户提出修改 → 生成新版本 → 形成行动草稿”。这条路径直接复用当前研究与知识库资产，能检验上下文、文件交付与用户复用。具体行业用户尚未确定，该场景是建议起点。

当前普通对话组装仍将全部历史转换为 role/content，工具 UI 恢复不等于模型上下文恢复；研究仍直接在 HTTP 流生成器内执行。建议把最小持久 worker 提前到 v0.3 的试用收口阶段，让关闭页面只影响订阅；v0.4 再做完整上下文压缩、预算分配与执行器优化。[本地执行器](#)、[流接口](#)

Deep Agents 实验的硬条件

1. 独立依赖环境，固定发布包与模型；主应用保持可回退。现有锁文件低于候选 LangChain/core 要求，先解析兼容性，再做真实调用。
2. 现有授权工具只是候选的一部分；检查并限制其内置文件工具、子代理和执行工具。多用户存储显式设置租户/用户命名空间，身份由服务端注入。
3. 先使用任务隔离的虚拟工作区，不开放任意 shell。代码执行以后加入独立沙箱；业务凭据由宿主工具持有。
4. 建立事件适配层，保留 AI SDK 的稳定 tool_call_id、审批与产物关联；不要把候选的 Beta v3 stream 当作已有协议的直接替换。
5. 首轮只读研究；真实写入保持单一 workflow 执行责任，避免双重审批或恢复后重复执行。

来源：[LangChain: Backends](#)、[工具与权限](#)、[事件流](#)，本轮复核于 2026-09-07。文件权限不等于沙箱隔离，检查点也不保证外部事务可回滚。

采用决策

12 个复杂任务、每例三次、相同模型与预算，比较基线和候选。权限、恢复、取消、审批关联和产物完整性必须全部通过。质量或返工至少一项明显改善且费用满足预设上限，才扩大试点；收益不明则继续现有实现。本文没有运行这一实验，不能给出性能胜负。

迭代计划与最终验收

本页调整上一版的实施顺序；后附 9 月 4 日报告保留原始研究记录。发生冲突时，以本页为准。全部是计划建议，尚未实施。

阶段	核心交付	放行标准
v0.3a 最小交付	TaskRun、Artifact、报告/来源、修订与版本；复用研究逻辑	一项任务能完整交付；失败不标成功；产物越权读取被拒
v0.3b 内部试用	真实账号、密钥撤销、基本审计与配额；单 worker 持久领取、重连与取消	3-5 人可独立使用；页面断开后任务有明确状态；重启恢复与备份演练通过
v0.4 长任务增强	ContextBuilder、原文卸载、摘要、预算；完成 Deep Agents 对照实验	长对话约束可恢复；预算不重置；候选采用/停止有证据
v0.5 业务行动	一个真实系统连接；审批具体参数、回执、对账；按需加入代码沙箱	重复提交和崩溃不盲目重放写操作；业务结果可查询确认
v0.6 技能与协作	有版本的方法包；2-3 个受限子任务；共享预算和取消	相比单 Agent 有实测收益；子任务不扩大权限
v1.0 持续交付	两个高频场景；质量回归、运维、备份恢复与责任归属	连续四周观察使用价值；负责人验收；服务指标由实际使用确定

首个十个工作日

第 1-2 日确定首批使用者、20 个任务样本与产物验收规则。第 3-5 日完成最小任务记录和报告发布接口；前端展示状态、来源和文件。第 6-8 日打通修订版本、隔离验证与持久 worker 冒烟。第 9-10 日评审完整样本，确认 v0.3b 身份与运维剩余项，并完成 Deep Agents 依赖兼容结论。

这是范围顺序，非承诺日程。新增 worker 前移会增加 v0.3 工作量；上一版两人团队 13-19 周的总估算只能保留为粗略参考，必须按可用人力和明确任务重新估算。不得把单人和双人工作量直接等同。

成功看什么

核心指标为任务合格率、引用支持率、人工复核返工时间和每个合格结果的总成本。初始 20 个任务各三次，失败与超时计入分母；单独测试越权、撤权恢复、重复审批、断连、超时、崩溃和写后无回执。多 Agent 数量、消息数和工具数只作诊断。

v1.0 的最终标准是用户持续委托真实工作，系统能在授权和预算内交付、解释失败并交接。任务结束、文件校验通过和用户验收通过应分别记录。

证据与限制

这次是对上一版研究的定向复核：刷新用户三入口、Claude 官方机制、Deep Agents SDK/backends/events/依赖/PyPI、DeepSeek safety，以及当前 Git 差异与执行主链路。没有重跑应用测试、安装候选执行器或比较性能；没有验证全部外部文档的当日变化。附录中的其余证据仍为 2026-09-04 访问记录。

后续检索已收敛：架构方向有一手依据，剩余问题需通过用户样本、兼容实验与故障测试回答。本报告使用既有研究，不重复启动三条完整研究线。下一项具体交付应为 v0.3a 实施规格与验收样本。

观心 v2：从 Agent Demo 到企业任务执行平台

Claude Code · LangChain Deep Agents · DeepSeek Harness

架构研究与迭代路线 | 2026-09-04 | 面向产品与技术负责人

建议决策

保留观心的平台与业务控制层，以可验证的任务交付为目标，渐进建设自己的运行时边界；将 Deep Agents SDK 作为复杂任务执行器候选，将 Claude Code 作为交互与任务闭环参照，将 DeepSeek Harness 作为模块化架构参照。

当前优先级是任务、产物、上下文和可靠执行。直接替换整个后端、复制终端编码产品，或先建设通用多 Agent 编排，都不能由现有证据证明有更高收益。

最终目标

观心成为企业内部可治理的 AI 工作平台：用户给出目标与授权资料，系统制定必要的计划、调用工具、交付可核查产物，并把经过确认的行动落到业务系统；长任务能继续、费用可约束、结果可追溯、责任可交接。

未来一个阶段最重要的成果

交付一个真正可试用的“研究与分析工作台”：同事可以提交资料和问题，获得带来源的报告及行动草稿，查看任务进度、历史版本、失败原因与运行成本。先证明一个高频场景持续有人使用，再扩展到真实业务写操作。

阅读边界

本文是决策建议，未批准实施、未进行依赖升级或生产部署。以 guanxin-v2 的 a59fd0c 封版提交及本轮本地代码核对为基线；已有前端工作区修改未纳入能力验收。外部文档按访问日解读，版本号与默认行为在实施时须再次锁定。

假设两名工程师投入、产品与测试人员兼职协作，首批为少量内部用户。时间范围是工作量估算，业务场景、人员和模型预算仍待确定。本轮未运行第三方框架基准，不宣称某个框架更快、更便宜或更准确。

01 现有基础与真正的缺口

观心已经具备有价值的技术底座。下一轮应围绕它做增量建设，而不是把已验收链路重新实现一遍。

领域	本轮确认的状态	对演进的含义
Agent 执行	Supervisor 区分直接回答、只读工具、研究与写工作流；只读循环上限为 4 回合 / 8 次调用	保留轻量路径；长任务另设可配置预算与执行器
权限与工具	Tool Catalog 按租户配置、角色和风险过滤；写工具走工作流	作为所有候选执行器必须遵守的控制边界
工作流恢复	LangGraph checkpoint、参数表单、审批、幂等记录、uncertain 人工接管已存在	将恢复扩展到一般任务；不能据此承诺外部写入全局 exactly-once
知识与研究	文档解析、向量检索、来源、预算、研究状态持久化已实现	优先产品化报告交付和证据核查
会话上下文	UI parts 可保存；普通对话重新给模型组装历史时使用全部 role/content，未见此路径的预算化压缩与完整工具历史投影	UI 恢复与模型继续工作是两种能力，需要分别验收
运行与产物	研究在 HTTP 流生成器中直接执行；有研究专用记录，未见统一持久任务 worker 和通用产物服务	建设任务执行与浏览器连接解耦的机制，不仅增加代理超时
身份与上线	登录用户/API Key 为进程内预设；当前定位为本地 Demo	内部多人试用前补真实账号、密钥撤销、审计、配额、备份恢复

以上基于静态代码核对，未做本轮断网、进程崩溃或并发实验。对“尚未具备”的判断限定在已检查的主链路。本地验收报告记录七组真实依赖场景、151 项后端测试、4 项 Chromium 场景通过；这是已有验收证据，本轮未重跑，也未重新核对 GitHub 最终发布状态。

证据：[封版验收报告](#)、[执行器](#)、[工具目录](#)、[流式接口](#)、[工作流引擎](#)、[身份存储](#)。

02 三个参考项目分别提供什么

Claude Code：学习任务完成方式

官方将核心行为描述为收集上下文、采取行动、验证结果，并依据结果继续调整。终端、桌面、IDE 与 Web 等入口共享底层循环。会话恢复、上下文压缩和跨会话记忆属于不同机制；文件检查点不覆盖数据库、API 或部署副作用。[Anthropic：How Claude Code works](#)

用户提供的中文页面是第三方架构说明，其中“无 GUI”等定位与现行官方文档不同。本文只将其作为发现入口，不以其内部文件名、逆向分层或版本宏作为官方架构证据。[Claude Code Architecture：中文入口](#)

Deep Agents：评估可嵌入的执行器

用户链接指向 Deep Agents Code，即 dcode 终端产品。应评估的集成对象是独立的 Deep Agents SDK。它构建在 LangChain 与 LangGraph 上，组织文件上下文、子任务和记忆等能力。当前文档说明 v0.7 起规划为可选项，需显式配置 TodoListMiddleware。[LangChain：Code 产品](#)、[SDK 概览](#)

DeepSeek Harness：学习模块边界

官方仓库确认它由 DeepSeek 开发，基于 Cordis，采用插件化组合；目前仍为开发者预览，明确提示不兼容变更。架构将模型、工具、循环、持久化等能力分开组合，会话事实与运行时扩展事件也有区分。[DeepSeek：仓库说明](#)、[架构参考](#)

参照对象	对观心最有价值的借鉴	建议采用方式
Claude Code / Agent SDK	持续验证、用户中途纠正、任务上下文管理	先借鉴产品机制；如需编码专长，再单独评估 SDK
Deep Agents SDK	长任务的文件上下文、摘要、子任务与框架集成	独立实验，通过共同验收收集后局部接入
DeepSeek Harness	能力服务接口、执行前后策略、事件事实与投影	先借鉴接口设计；运行时接入后置且隔离

“deep agent”是能力范式，Deep Agents 是具体库，dcode 是产品，harness 是围绕模型的执行与控制系统。它们不能作为同一层的三个替换件直接比较。

03 定位与首个完整业务场景

选择企业任务平台作为主方向

候选方向有三种：个人编码助手、通用 harness 基础设施、企业任务执行平台。前两者分别要求更深的开发环境体验和框架生态投入；观心已有租户、知识、审批与结构化业务工具，更适合从第三种方向形成价值。这是基于现有资产的工程判断，仍需真实用户验证。

产品首先服务知识、研究、数据整理和运营流程。编码与浏览器操作是按需求接入的执行能力，不必成为首页版主界面或默认工具。

用本次研究任务作为产品样本

用户输入“结合这几份资料，研究系统演进路线”，系统应完成：

1. 建立任务，记录目标、输入、交付格式、验收标准和预算。
2. 检索授权资料与公开来源，记录证据、冲突与缺口。
3. 形成报告、路线和行动草稿，给出每项关键判断的依据。
4. 用户查看文件、版本差异、来源及运行消耗，并提出修改。
5. 系统继续同一任务，保留上下文；用户明确要求后，才将具体行动写入外部系统。

第一阶段只交付报告和行动草稿，支持下载与修订。真实工单、CRM 或消息平台写入放在后续可控阶段，并绑定目标系统的回执。

产品形态建议

保留对话作为入口，增加任务列表、运行详情、产物区和待处理决定。用户需要看到“正在做什么、已得到什么、为何暂停、下一步需要谁”，无需理解 LangGraph、MCP 或内部 middleware。

完成状态分开记录：运行正常结束、产物验证通过、业务负责人验收通过。模型的最终一句话不能独自决定任务是否成功。

价值衡量

核心指标是被用户接受的任务完成率、有效节省时间和每个合格结果的总成本。消息数量、工具数量或子 Agent 数量仅作参考信息。

v1.0 应表示至少两个真实场景可以持续交付，具备可测量的质量、权限、恢复与运维能力。它不等于“集齐所有参考产品功能”。

04 建议的目标架构

平台管理任务和责任，执行器完成受限工作，工具网关负责副作用，产物服务保存交付结果。以下全部为拟议设计。



平台层保持稳定

FastAPI 继续拥有认证、租户与用户授权；现有 AI SDK / assistant-ui 继续承担交互。新建最小 TaskRun 和 Artifact 服务，关联现有 conversation、workflow 和 research 标识，不在第一轮改写全部历史表。

TaskRun 建议包含 goal、owner、inputs、budget、status、executor_version、parent_run_id。Artifact 建议包含所属运行、版本、内容哈希、来源、类型、校验结果和存储位置。产物下载也必须经过归属校验。

执行器作为可替换实现

先为当前执行路径定义一个薄适配接口，例如 start、resume、cancel、get_state 和 stream_events。研究候选实现可使用 Deep Agents；其他执行路径继续使用现有实现。稳定接口以实际出现的第二种实现为边界，避免预先开发完整插件框架。

用增量事件统一观察，不急于全面事件溯源

记录 run/step/tool/approval/artifact 的关键持久事实，使用 run_id、event_id、递增 sequence、schema_version 和父子关系。进度通知和展示快照从这些事实生成。DeepSeek Harness 的事实日志与投影分离值得参考，但其完整 Cordis/Typert 架构没有必要整体迁入 Python 平台。[DeepSeek：架构参考](#)

业务状态与关键事件优先在同一数据库事务提交；跨存储副作用用幂等键、回执和对账处理。LangGraph checkpoint 存执行位置，任务表存业务状态，两者通过运行 ID 和恢复规则关联，不能互相冒充唯一事实来源。

统一权限的最后一关

所有工具调用，包括框架自带文件工具和子 Agent 调用，都进入同一可审计政策。调用方身份由服务端注入。宿主服务持有业务凭据；执行器只得到完成任务所需的能力。模型提供的 tenant_id、角色或许可文本不改变授权。

05 上下文、记忆与技能应如何演进

先解决上下文失真与无限增长

本地普通对话组装将历史转换为 role/content，说明保存完整 UI parts 不等于下一轮模型能恢复同样的工具事实。建议引入 ContextBuilder：明确系统约束、当前目标、近期对话、已核验结果和按需材料；将旧工具输出转为可检索引用，并保存原文。[本地执行器](#)

层次	应保存什么	规则
权限与政策	身份、角色、资源范围、工具风险	确定性配置，不由摘要决定
运行事实	工具调用、审批、来源、回执	持久化；可追溯，不被摘要覆盖
工作上下文	当前目标、约束、阶段结果	有 token 预算；可重新构建
工作文件	长报告、检索结果、分析中间数据	按任务隔离，按需读取
长期记忆	用户偏好、项目约定、经验	显式归属、来源、版本、删除能力
业务知识库	可授权检索的组织文档	由资料维护流程更新，保留出处

Claude 的记忆文档强调记忆是上下文而非强制配置；其 Skills 支持按需加载。Deep Agents 的上下文机制包括长结果卸载与摘要，但具体阈值是版本实现细节，不适合作为观心不可变的产品规则。[Anthropic：Memory、Skills、LangChain：Context engineering](#)

区分技能说明和可执行工具

当前 BaseSkill 是 Python 可执行插件。建议新增“工作方法包”，以 SKILL.md 和资源描述目标、步骤、输入、产物格式与验证样例，并以独立 manifest 保存版本、工具需求和批准范围。方法包组合工具，不能通过提示词获得更高权限。[本地 BaseSkill](#)

先做三份方法包：资料研究、知识问答、表格分析。每份附带少量真实验收样本。共享记忆不默认从聊天自动写入；先让用户确认稳定事实，并提供查看与删除入口。

多用户 StoreBackend 必须显式定义 namespace。本系统建议至少区分租户、用户或项目、用途；身份来自运行上下文，不来自模型参数。[LangChain：Backends](#)

06 长任务与外部行动的可靠性

将任务生命期与浏览器连接分开

当前研究直接在请求流中执行。建议由 TaskRun 接收任务、持久队列交给 worker、浏览器订阅事件。关闭页面只断开订阅；取消任务是另一个显式动作。重连依据 sequence 补齐事件，而不是重新提交一次任务。
[本地 AI SDK 接口](#)

第一版可以是单 worker 与数据库队列，但应有任务领取、租约、heartbeat 和过期任务处理；不能把进程内 create_task 当作持久队列。多 worker 出现后再扩展并发存储与协调方案。

恢复按副作用分类

场景	建议恢复行为
只读检索超时	在剩余预算内有限重试，保留失败事实
等待补充信息/审批	恢复同一运行与决定；重新检查当前权限
文件产物发布	先临时生成、校验，再提交版本；幂等发布
外部写入已收到回执	保存回执，恢复时返回已完成结果
写入后崩溃但无回执	先查询外部状态；无法确定则 uncertain 人工接管

观心现有工作流已经处理审批和不确定状态，应保留并扩展。所谓“恢复”不能被理解为重复播放所有工具调用。Claude 的文件检查点也不覆盖外部系统变化。[本地工作流引擎](#)、[Anthropic : Checkpoints 边界](#)

每次批准绑定一个具体动作

绑定 actor、run_id、tool_call_id、目标资源、规范化参数摘要、版本和有效期。参数或权限改变后重新判断批准是否仍有效。优先在 Tool Gateway 完成执行前鉴权与参数校验，执行后记录回执；后置钩子不能撤销已经发生的副作用。[Anthropic : Permissions](#)、[Hooks reference](#)、[DeepSeek : 工具流水线](#)

取消与预算要覆盖整棵任务树

父运行统一分配总 token、工具调用、时间与金额上限；子任务预留预算，结束后结算。取消后禁止启动新动作；对已发出的外部写请求查询结果并说明状态，不能宣称点击取消等于回滚。模型结束、预算耗尽、阻塞和验收通过必须有不同终态。

07 Deep Agents 接入实验怎么做

已发现明确版本差距

本轮可见 PyPI 发布包为 deepagents 0.7.13，2026-09-02 上传；main 的 pyproject 同为 0.7.13，要求 Python ≥ 3.11 、LangChain ≥ 1.4 、langchain-core $\geq 1.6.1$ 。观心当前 uv.lock 与实际环境为 LangChain 1.3.13、core 1.4.9、LangGraph 1.2.9。不得据此推断直接安装兼容。[PyPI 发布记录](#)、[官方依赖声明](#)、[本地锁文件](#)

独立候选环境与共同契约

建立独立 lockfile 和 worker 环境，记录已解析依赖与模型配置。选取 12 个资料研究/报告任务，对比当前执行器和候选执行器；每例重复三次。先固定同一可用模型、相同工具、输入、预算和验收口径，再单独研究模型差异。

候选只得到当前租户授权的只读工具；使用任务隔离的 StateBackend 或受控 backend，暂不开放任意 shell。执行器产出文件由宿主校验后发布到 Artifact 服务。

不能遗漏的框架默认行为

自定义 tools 参数增加工具，不会自动移除内置能力。需显式检查候选实际暴露的文件工具、子代理和执行工具，并逐一收口。当前权限规则无匹配时允许，且不覆盖任意命令执行的 sandbox 后端；本地 FilesystemBackend 也被官方列为不适合 Web server/HTTP API。[LangChain：工具与权限](#)、[Backends](#)

HITL 依赖 checkpointer 与相同 thread_id 恢复；一次中断可能涉及多个动作。观心的审批 ID、动作顺序、用户身份及恢复语义必须经过适配测试。[LangChain：Human-in-the-loop](#)

新 event streaming 页面仍标 Beta，其 v3 事件不是 AI SDK 协议。先转换为观心自己的运行事件，再生成现有 UIMessage parts；摘要流和子任务内部输出不能混入最终回答。[LangChain：Event streaming](#)

采用或停止的判据

先要求权限、审批、恢复、取消与流协议契约全部通过。再观察报告合格率、返工、延迟和有效成本是否优于基线；小样本只支持继续试点，不支持宣称普遍优胜。如果没有明显收益，继续现有 LangGraph 实现，并仅吸收验证有效的机制。

08 版本路线与阶段门槛

版本名是建议，不代表已排期。按两名工程师与兼职产品/测试估算；范围确认后重估。各阶段以前一阶段验收为依赖，避免同时重写运行时、身份和业务流程。

阶段	预计工作量	核心交付	退出条件
v0.3 任务与产物	3-4 周	首个研究/分析场景；TaskRun、Artifact、来源和版本；真实账号、基本审计与用量记录	用户独立提交、获得文件、提出修订；归属校验与关键路径通过；开始 3-5 人试用
v0.4 持久执行与上下文	3-4 周	worker、持久队列、重连/取消、统一预算、ContextBuilder；完成 Deep Agents 独立实验	断开页面不中断已接收任务；重启状态一致；长上下文不丢关键约束；决定采用或停止候选
v0.5 可控业务行动	4-6 周	一个真实系统连接；具体行动审批、回执、对账；按需求加入隔离代码执行	代表性流程端到端完成；故障注入不盲目重放写操作；可确认实际业务结果
v0.6 技能与有限协作	3-5 周	方法包版本化；2-3 个受限子任务；共享预算、取消与聚合；按需求接入第二执行器	多任务收益超过协调开销；权限不扩大；子任务失败可被解释或接管
v1.0 可持续使用	前述门槛后另行评估	两个高频场景稳定运行；备份恢复、运维、质量回归和服务指标	连续 4 周观察质量、使用 and 成本；业务负责人确认价值；完成上线演练

前四阶段约 13-19 个工程周，是范围级估算，不含 v1.0 观察期及外部系统审批等待。单人兼顾全部工作时需要重新安排，不能简单沿用该时间表。

先后顺序的理由

产物与任务状态先让用户获得价值，也为后续运行时比较提供统一输出。后台执行和上下文随后解决长任务稳定性。真实业务写入依赖身份、审计、恢复与对账。多 Agent 只有在任务可拆、结果可验、预算可控时才有意义。

可以提前与应该后置的工作

Deep Agents 的短期兼容实验可以在 v0.3 末提前开展，但不阻塞基本场景交付。DeepSeek Harness 接入、通用 DAG 画布、插件市场、自动共享记忆、任意浏览器操作和自动循环优化都后置到有明确使用证据时。

09 首个 10 个工作日的任务清单

目标是产出可评审的最小闭环和基线，覆盖 v0.3 的第一部分；不是在十天内交付整套平台。下表均为待实施建议。

工作日	负责人建议	工作与具体交付	验收
1-2	产品 + 后端	选定一种使用者与高频任务；收集 20 个知识/研究/分析样本；定义产物模板和评分表	每例有输入、预期结果、来源范围、人工基线；业务负责人认可
2-3	后端	保存当前依赖与测试基线；定义 TaskRun/Artifact/RunEvent 最小字段、状态与版本	文档可说明 conversation、research、workflow、checkpoint 的关联和恢复责任
3-5	后端	包装现有研究路径，记录运行、来源、结果、消耗；产物幂等发布	同一运行刷新后可查询；失败不得发布“成功产物”；越权读取被拒
4-6	前端	任务详情、产物下载、来源与版本；沿用现有会话与审批呈现	用户能找到报告、看懂状态并继续修订；不要求理解技术模块
6-7	后端 + 测试	真实身份存储与密钥生命周期设计/最小实现；归属、日志脱敏、备份路径	账号重启可用；密钥可撤销；新增接口隔离测试通过
7-8	后端	独立 Deep Agents 环境依赖解析与冒烟；检查内置工具、模型调用、结构化输出与事件适配	输出明确兼容矩阵；不污染主环境；不开放 shell 或生产写工具
9-10	全体	最小闭环演示、样本评审、回归；列出余下 v0.3 工作与候选实验差距	形成可复核记录、优先级和采用/继续实验/停止三选一建议

候选实验的 12 例 × 3 次完整对比，可在依赖冒烟成功后完成；不把它和生产身份迁移强行塞入同一天。若资源只有一人，按表中的依赖顺序执行，前端与后端不并行承诺。

建议首批变更范围

新增任务/产物模型、存储和 API；在现有研究结果出口增加发布适配；前端增加任务结果入口。现有工作流审批保持兼容。对执行器历史组装与统一事件的深度改造留到 v0.4。

本轮必须做出的三个决定

确定首批用户与最常见任务；确定内部试用环境和可使用数据；确定候选实验允许的模型与总费用上限。本文给出了默认方向，尚未将这些假设当作用户已确认的产品要求。

10 如何证明演进确实有效

同一任务集、同一预算、分层验收

首批建议固定 20 个正向任务：6 个知识问答、8 个资料研究报告、6 个结构化数据分析。每例运行三次，共 60 次；另建 20 个权限与故障场景独立验收。进入真实业务写入阶段时扩充任务集并建立新基线，不混用不同范围的分母。

指标	测量方式	建议初始门槛，不是已达结果
任务合格率	负责人按预设 rubric 判断是否无需重大修改；失败和超时计入分母	首轮 $\geq 48/60$ ；成熟目标 $\geq 54/60$ ，均只对固定样本有效
关键结论有证据支持	人工逐项核对关键事实与引用原文；缺证据须明确标注	$\geq 95\%$ ；不以“链接存在”代替支持结论
权限与副作用	越权读写、撤权后恢复、重复审批、写后崩溃等独立用例	全部通过；零观察违规不代表真实世界零风险
有效成本	全部调用费用及失败重试费用 / 合格结果数；人工返工时间另列	先建基线，再由任务价值设上限；不预设虚构单价
延迟与控制	记录总耗时、首个有效进度时间、取消到停止新动作的时间	报中位数与 P95；小样本仅作诊断，目标由使用者确认
实际节省时间	对同类任务比较人工操作时间 + 复核返工时间	两周试用建议观察中位数降低 $\geq 30\%$ ，未达需复盘
持续使用	记录试用者主动复用的任务、原因和失败点	3-5 人中多数在第二周继续主动使用，非强制打卡

故障用例必须贴近真实执行

覆盖浏览器断开、模型超时、worker 重启、租约过期、来源不可用、超预算、取消、产物发布中断、工具权限变化、重复恢复、审批参数变化，以及外部写入成功但回执丢失。对未知结果优先显示不确定并对账。

多 Agent 的单独准入标准

先测试单 Agent，再对可独立拆分的资料提取或复核使用 2-3 个子任务。比较同一输入的完成率、关键遗漏、总费用、总时间和汇总损失。只有收益超过通信与复核成本才扩大使用。子任务有独立上下文并不自动形成进程或租户隔离。[Anthropic：Subagents](#)、[Sandboxing](#)

11 技术选择、风险与调整条件

现在采用的原则

保留 Python/FastAPI/LangGraph 与 AI SDK 接口。保留已验证的写工作流和租户知识库。使用版本化任务与事件契约隔离框架变化；从业务任务需要出发引入能力。实际改造中只抽取受影响接口，避免为“未来可扩展”先创建大规模插件系统。

沙箱必须作为单独能力验收

当任务需要执行生成代码时，采用独立工作区、资源与时间限额、网络约束和受控文件导入导出。业务密钥留在平台侧，通过授权工具访问。LangChain 推荐的 sandbox-as-tool 模式可作为参照。[LangChain : Sandboxes](#)

DeepSeek 的进程 sandbox 词汇主要定义文件效果，不包含网络和进程可见性的完整隔离承诺；其安全说明还明确表示未经过安全审计，不能当作生产就绪系统。若后续接入，应先作为可替换、隔离的实验执行器，而不承担平台唯一安全边界。[DeepSeek : Sandbox](#)、[Safety](#)

什么时候重新考虑路线

观察到的情况	调整动作
真实需求主要是修代码、跑测试、提交 PR	转向开发者工作台；单独比较 Claude Agent SDK 与编码执行器
Deep Agents 无质量收益且引入较高升级成本	停止集成，保留现有实现与已验证设计
大部分业务流程稳定、确定、步骤固定	优先明确工作流与表单；减少自由规划
并发 worker、数据库锁或任务量成为实测瓶颈	再评估数据库、队列和执行调度升级
多租户与部署要求变化	重做隔离、凭据、数据保留和运维边界评审
真正需要多模型或多 harness 的专长	增加第二适配器；不把所有实现强制抽象为最低共同能力

Claude Agent SDK 是可编程的接入对象，不能把终端登录或订阅额度直接等同产品后端授权。后续采购、云部署或对外服务前，应按实际方案重新核对商业条款与数据要求；本文没有做价格或云服务采购比较。

[Anthropic : Agent SDK overview](#)

12 证据范围与结论强度

可以据此决策的部分

三个参考对象的层级、主要机制和显著接入边界已有官方文档支持。本地代码和锁文件支撑了现有平台能力、上下文组装、HTTP 执行绑定以及依赖差距的判断。可据此决定先做任务闭环、保留治理层、隔离候选实验。

仍需实验和产品确认的部分

没有运行 Claude Agent SDK、Deep Agents 或 DeepSeek Harness；没有在相同任务集上比较质量、费用或延迟。没有审计它们全部源码或验证多租户生产安全。没有确认业务系统 API、首批用户、可用数据与团队投入。路线和工期都是建议，不能作为已承诺交付日期。

Deep Agents 的包元数据保留 Beta 分类，部分官方文档有旧版迁移文字残留；本文优先使用当前明确说明与可见发布元数据，仍要求实施时锁版本验证。DeepSeek Harness 的技术预览状态已确认，本轮没有确认具体首次发布日期和统一稳定版本；不以热度或发布时间判断成熟度。

来源说明

全部网页访问于 2026-09-04；除 PyPI 的 0.7.13 发布记录为 2026-09-02 外，本报告所引用文档未核实到可靠的页面更新时间。抓取日期不等于发布日期。来源发布者分别为 Anthropic、LangChain、DeepSeek；中文 Claude 架构页为第三方发现资料。主文已在关键判断附近提供可点击的具体来源。

本地证据基线为 a59fd0ce0c58f3a727efb00aeb31ecd3246432fc。核对 README、封版验收报告、uv.lock，以及 agent、workflow、research、auth、conversation 和 skill 主链路。已有验收记录与本轮静态核对分开陈述；外部框架能力没有被表述为本系统已实现。

研究采用三条来源线，先读用户给定入口，再核对官方文档、依赖元数据与关键反例。停止扩展检索的原因是：剩余最重要的未知项已变成兼容性、实际收益与使用需求，这些应由实验和试用回答。

建议立即推进的决定

将下一阶段定义为“观心 v0.3：研究与分析任务工作台”。先用同一组真实任务证明完整交付能力；同时准备一个受限的 Deep Agents 兼容性实验。以任务结果、责任边界与用户复用来决定后续技术投入。

最终交付对象是一项完成且可核查的工作。框架、模型与多 Agent 机制，是实现这一目标的可替换手段。